

Analyse économétrique de données spatiales pour évaluer l'impact de politiques et de projets

Introduction



Florent Bédécarrats, Thomas Thivillon



Le contenu de cette formation est largement tiré de Bédécarrats, Bouvier, Hounghedji; de Montalembert, Ferry. 2022. Impact des aires protégées sur la déforestation : guide de formation pratique, Tany Vao, IRD. [En ligne](#).


Tour de table

Présentation de chaque participant


Attendus de la formation

Niveau d'expérience préalable avec R, l'évaluation d'impact et les données spatiales

Attentes exprimées dans le questionnaire




Profils



Expérience en analyse de données

Avez-vous déjà travaillé avec des données ?

18 réponses



- Jamais
- Oui, uniquement dans Excel ou un tableur
- Oui, dans un logiciel statistique
- Oui, pour des analyses descriptives
- Oui, pour des modélisations statistiques

Objectifs de la formation

- Formation aux méthodes d'évaluation d'impact
- Accent sur les données spatialisées et les traitements statistiques qui s'y rapportent
- Fil rouge de ces travaux est l'impact des aires protégées sur la déforestation
- Alternier sessions théoriques et pratiques pour favoriser la réutilisation des principes
- Se familiariser avec un outil (package mapme.biodiversity) qui facilite l'acquisition de données spatiales et leur transformation en indicateurs exploitables pour l'évaluation économétrique
- Formation largement fondée sur les [supports élaborés pour l'université Tany Vao 2022](#) avec Jeanne de Montalembert, Marin Ferry et Marc Bouvier

Programme de l'atelier

- **Jour 1 (1^{er} juillet) :**
 - Matin : Introduction et cadrage théorique.
 - Après-midi : Initiation à R
- **Jour 2 (2 juillet) :**
 - Matin : Principes de l'évaluation d'impact avec contrefactuel.
 - Après-midi : Initiation à R (suite)
- **Jour 3 (3 juillet) :**
 - Matin : Revue des types de données.
 - Après-midi : Initiation à R (fin)
- **Jour 4 (4 juillet) :**
 - Matin : Données spatiales (travail avec les données vectorielles et raster)
 - Après-midi : Données spatiales (opérations avec les packages sf et mapme.biodiversity)
- **Jour 5 (7 juillet) :**
 - Matin : Expérimentations aléatoires (théorie)
 - Après-midi : Expérimentations aléatoires (application)
- **Jour 6 (8 juillet) :**
 - Matin : Comparaisons avant-après ; Clarifications sur les unités d'analyse
 - Après-midi : Méthodes d'appariement (théorie)
- **Jour 7 (9 juillet) :**
 - Matin : Méthodes d'appariement (application)
 - Après-midi : Méthode des doubles différences (théorie)
- **Jour 8 (10 juillet) :**
 - Matin : Méthodes des doubles différences (application)
 - Après-midi : Projet de groupe.
- **Jour 9 (11 juillet) :**
 - Matin : Exercices pratiques dans R.
 - Après-midi : Restitution, évaluation et conclusion.

Jour 1 : Fondements théoriques

Objectifs de cette session

- Spécificité des évaluations d'impact dans la « boîte à outils » évaluative
- Enjeux de l'évaluation d'impact
- Cadre d'analyse économétrique de la causalité : le cadre des résultats potentiels de Rubin
- Affiner sa compréhension des mécanismes de causalité : diagrammes acycliques orientés et combinaisons quanti-quali
- Tour d'horizon des principales méthodes d'évaluation d'impact

Spécificités de l'évaluation d'impact scientifique

Attention aux différentes acceptions de l'évaluation

- Terme très usité:
 - Signification parfois floue
 - Même quand bien défini : différents référentiels
- Deux cadres bien définis qui ont des définitions différentes
 - Référentiel des politiques et projets de développement
 - Référentiel scientifique d'identification causale

Qu'est-ce que c'est que l'évaluation de politique ou de projets ?

- Définition du CAD OCDE (2000)

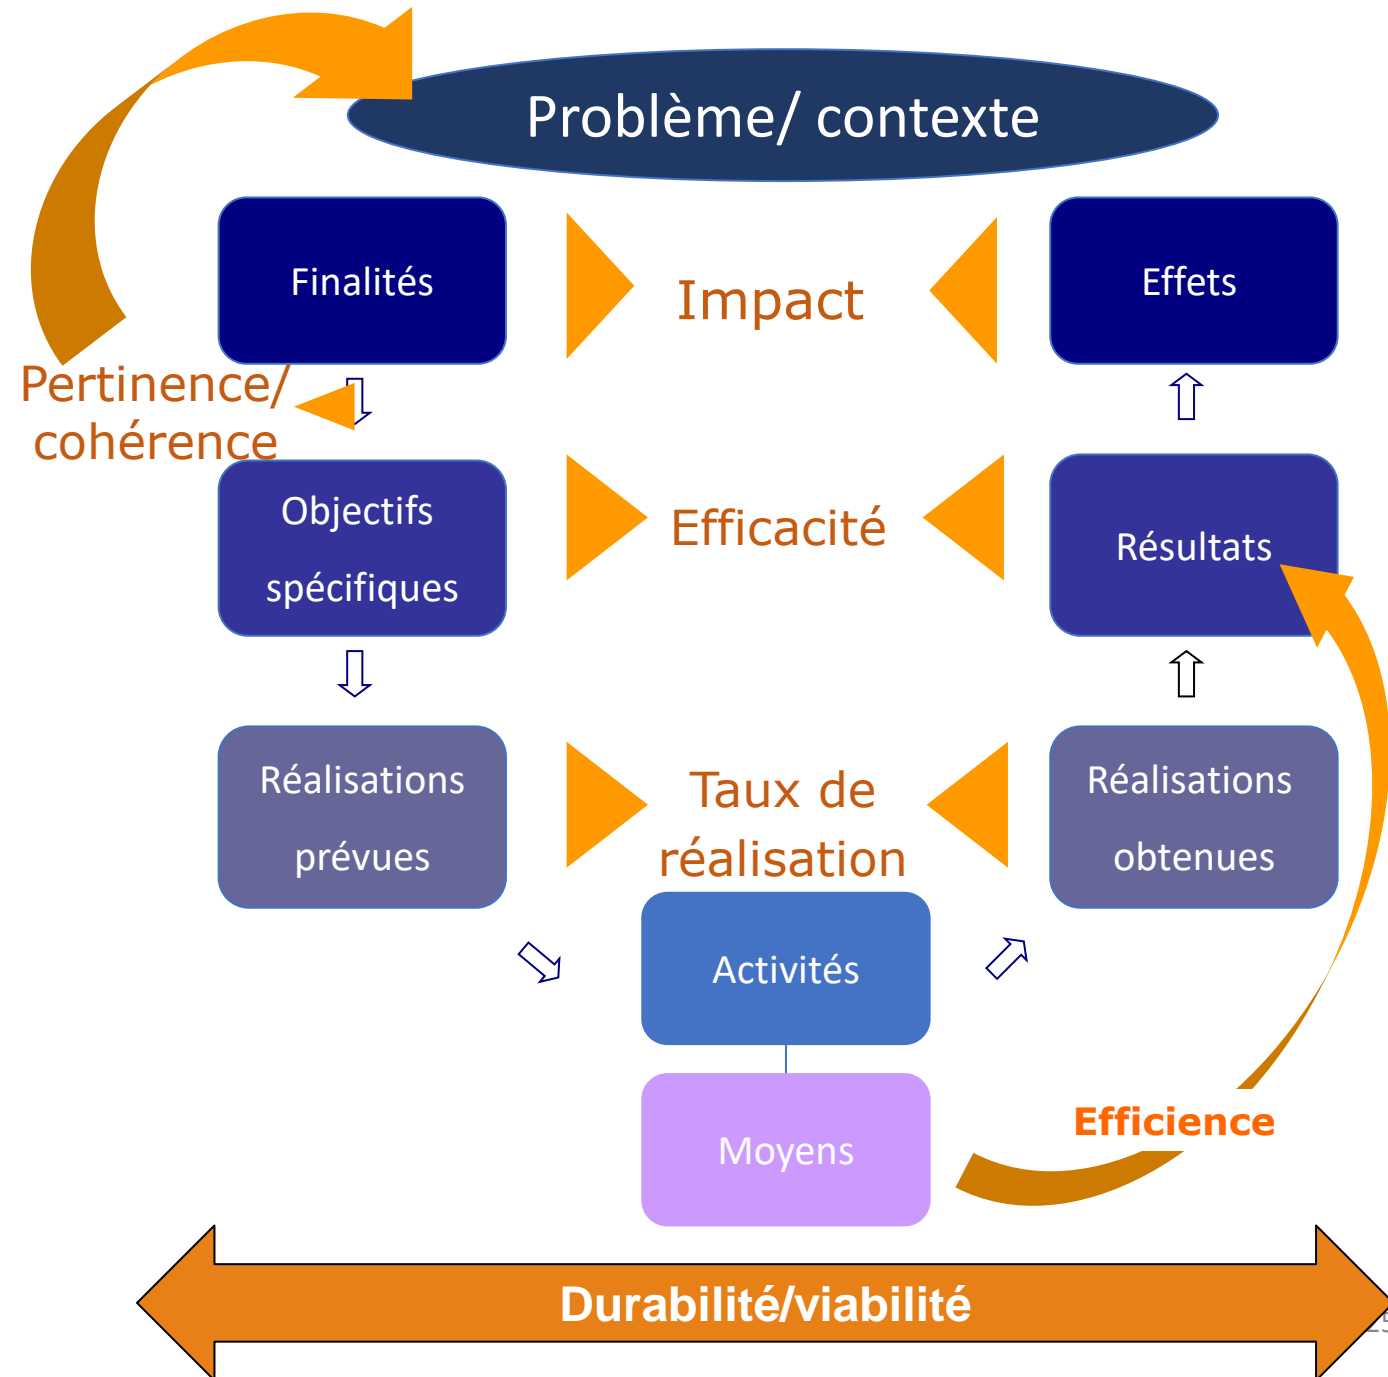
« **Appréciation** systématique et objective d'un projet, d'un programme ou d'une politique en cours ou achevé, de sa conception, de sa mise en œuvre et de ses résultats. Le but est de déterminer la pertinence, le niveau d'atteinte des objectifs, l'efficience (...), l'impact et la durabilité».

« évaluation » désigne également un processus aussi systématique et objectif que possible par lequel on détermine la valeur et la portée d'une action de développement

<http://www.oecd.org/dac/dac-glossary.htm#Evaluation>

Relation entre logique d'intervention et critères d'évaluation

- **Pertinence:** Les objectifs de l'évaluation correspondent-ils aux problèmes identifiés?
- **Cohérence:** L'intervention est-elle compatible avec le contexte général?
- **Efficacité:** L'intervention a-t-elle atteint ses objectifs prévus?
- **Efficience:** Les ressources allouées à l'intervention ont-elles été bien utilisées?
- **Impact:** L'intervention a-t-elle conduit à un changement réel et mesurable pour les bénéficiaires?
- **Durabilité/viabilité:** Les bénéfices de l'intervention peuvent-ils perdurer dans le temps?



Différentes acceptions de l'impact

Approche classique de l'évaluation du développement

- **Définition** : « Mesure dans laquelle l'intervention a produit, ou devrait produire, des effets importants et de vaste portée, positifs ou négatifs, intentionnels ou non. » (CAD-OCDE, 2019)
- **Spécificités** :
 - Adopte une perspective **holistique**, englobant une gamme variée d'effets.
 - Est orientée vers des effets **durables** et de **long terme**.
 - Reconnaît l'existence d'effets **non intentionnels**, qu'ils soient positifs ou négatifs.

Approches scientifiques (en particulier économétriques)

- **Définition** : « La différence entre le résultat observé avec l'intervention et le résultat qui aurait été observé sans elle. » (Angrist et Pischke, 2009)
- **Spécificités** :
 - Se focalise sur des effets à **court terme** : relèvent souvent de l'efficacité.
 - Adopte une rigueur méthodologique pour isoler l'effet de l'intervention des autres facteurs.
 - Priorise la **causalité**, cherchant à déterminer les effets directs et mesurables d'une action.

Discussion

Que pensez-vous de ces définitions de l'impact ?

Qu'est-ce qui manque selon vous ?

Les enjeux de l'évaluation d'impact

**Le problème d'identification et les corrélations
fallacieuses**

Le problème d'identification (exemple 1)

- Exemple de Angrist et Pischke (2009, p. 10-12) tiré de l'enquête nationale sur la santé aux Etats-Unis en 2005
- Relation entre :
 - états de santé : de 1 (excellente santé) à 5 (santé très dégradée)
 - le fait d'être allé à l'hôpital au cours des 12 derniers mois ?

| Groupe | Taille de l'échantillon | Statut de santé moyen | Erreur standard |
|--------------|-------------------------|-----------------------|-----------------|
| Hôpital | 7774 | 2.79 | 0.014 |
| Sans hôpital | 90049 | 2.07 | 0.003 |


Quelle conclusion pouvez-vous en tirer sur l'impact de l'hôpital sur la santé ?

Le problème d'identification (exemple 2)

- A New York et à Chicago, on observe une étroite correspondance entre :
 - Le niveau de ventes de glaces (crèmes glacées)
 - Le nombre de meurtres

Y a-t-il un impact de la consommation de glaces sur les meurtres ?

Le problème d'identification (exemple 3)



Source: <https://tylervigen.com/spurious-correlations>

Risques de biais d'identification causale si on se contente de corrélations naïves

Variable confondante : Variable Z influence à la fois X et Y. Si on omet de tenir compte de Z, on conclut à une relation causale erronée.

- Exemple : La relation entre les ventes de glaces et les taux d'homicides est confondue par la température.

Causalité simultanée ou inverse : Lorsqu'on présuppose que c'est X qui influence B, alors que c'est B qui cause A, ou que X et Y s'influencent mutuellement.

- Exemple : La relation entre l'hospitalisation et l'état de santé

Coïncidence : X et Y peuvent être corrélés purement par hasard, en particulier si la taille de l'échantillon est petite ou qu'on teste un grand nombre de variables.


- Exemple : La relation entre l'âge des Miss America et les meurtres par objets brulants

Exercice

Essayez de trouver un exemple de corrélation fallacieuse que vous avez rencontré dans votre vie professionnelle ou personnelle.

Clarification sur les manières de formaliser des liens causaux

- Exemple de modes de notation différentes :
- Diagrammes acycliques orientés (DAGs)
- Équations



$$Earn_i = \alpha + \beta \times Edu_i + \gamma_1 \times Year_i + \gamma_2 \times Loc_i + \gamma_3 \times Bkg_i + \gamma_4 \times JobCx_i + \varepsilon_i$$

Les ingrédients d'une équation simple

Variables : représentées par des lettres, elles sont soit dépendantes (expliquées par d'autres) soit indépendantes (elles expliquent)

- Exemple: Y pourrait représenter le revenu et X pourrait représenter des années d'éducation

Coefficients : valeurs constantes qui déterminent la relation entre les variables

- Souvent représentés par des lettres grecques comme α ou β

Équations: relient les variables et les coefficients.

- Exemple: $Y = \alpha + \beta X$

Quelques compléments

Indices : indiquent des éléments spécifiques dans un ensemble.

- Exemple: Y_i représente le revenu de la i -ème personne.

Deltas : Le symbole Δ représente un changement ou une différence.

- Exemple: ΔY fait référence au changement dans Y

• **Chapeau** : indique une estimation ou prédiction.

- Exemple: \hat{Y} est une prédiction de Y à partir d'un modèle

• **Macron** : représenter la moyenne (ou l'espérance) d'une variable

- Exemple : \bar{X} est la moyenne de X

• **Erreurs** (ou résidus) : Souvent notées ε représentent l'écart entre les prédictions d'un modèle et les valeurs réelles.

Les « DAG »

Qu'est-ce qu'un DAG?

- Graphique acyclique dirigé pour représenter des liens causaux.
- Les flèches indiquent la direction de la causalité entre variables.
- Pas de cycles; la causalité se déplace dans une seule direction
- L'absence de flèche indique l'absence de lien causal

Intérêts principaux :

- Interface entre la modélisation et la théorie économique, l'expérience de terrain, l'intuition, la littérature, le quali.
- Clarifie la question d'intérêt, les variables pertinentes et les hypothèses
- Formalisme en graphe permet une résolution logique pour le choix des variables à incorporer dans un modèle (et des tests à effectuer pour valider le modèle)
- Etablit un pont entre différentes écoles empiriques

Exercice

Imaginez un schéma causal qui représente les facteurs associant déforestation et conservation